제6회 K-인공지능 제조데이터 분석 경진대회 보고서

프로젝트명	*다중 AI 모델 기반 프레스 유압펌프 시계열 이상 탐지 및 현장 의사결정 지원 시스템*
팀명	*가즈아*
내용요약	본 프로젝트는 파인블랭킹 프레스 유압펌프의 진동·전류 시계열 데이터를 활용하여 설비 이상을 탐지하고 오경보 및 미탐지 발생조건을 분석하기 위해 수행하였다. 측정 공백을 고려한 Segment 기반 5-Step 시계열 특징을 생성하고 Isolation Forest, Autoencoder, XGBoost를 비교하여 Isolation Forest를 주 이상탐지 모델로 선정하였다. 또한 Autoencoder와 XGBoost 결과를 결합한 Hybrid Anomaly Score를 보조 위험도 지표로 활용하고 FP/FN 분석을 통해 신호 변화가 작은 이상 구간의 미탐지와 정상상태의 순간적 센서 변동에 따른 오경보 특성을 확인하였다. 이후 Temporal Persistence Rule을 적용하여 단발성 오경보를 억제하고 지속적인 이상 신호를 최종 경보로 연결하였다. 최종적으로 Isolation Forest 판정, 이상 위험도, 센서별 이상 기여도, Persistence 경보 및 점검 가이드를 제공하는 Gradio 기반 현장 진단·연속 모니터링 UI를 구현하여 AI 분석결과를 작업자의 설비 점검 의사결정으로 연결하였다.

상기 본인(팀)은 위의 내용과 같이 제6회 K-인공지능 제조데이터 분석 경진대회 결과 보고서를 제출합니다.

2026년 10 월 4 일

팀장 : 노용승 (서명)
팀원 : (서명)
팀원 : (서명)

(사)중소기업기술혁신협회 귀중

□ 제1장. 데이터 이해 및 진단 [15점]

○ 데이터 구성 및 제조공정 상태의 이해

본 프로젝트에서는 파인블랭킹 프레스의 유압펌프 모터에서 수집된 진동 및 전류 시계열 데이터를 이용하여 설비의 정상·이상 상태를 구분하고 이상징후 탐지 과정에서 발생하는 오경보 및 미탐지 조건을 분석하였다. 원본 데이터는 정상 운전 상태를 나타내는 press_data_normal.csv 20,000개 시점과 이상 상태를 나타내는 outlier_data.csv 600개 시점으로 구성되어 있다.

데이터 품질 점검 과정에서 정상 데이터에서 동일한 TimeStamp와 동일 센서 값을 갖는 중복 측정 1건을 확인하여 제거하였다. 따라서 최종 분석에는 정상 19,999개, 이상 600개로 총 20,599개 관측값을 사용하였다. 정상 데이터가 약 97.1%, 이상 데이터가 약 2.9%로 약 33:1의 불균형 구조를 가지므로 단순 Accuracy만으로 모델의 이상탐지 성능을 판단하기 어렵다고 보았다.

정상 데이터와 이상 데이터는 서로 다른 날짜에 수집된 독립된 측정 세션이다. 따라서 두 파일을 하나의 연속적인 정상→이상 변화과정으로 임의 연결하지 않고 각 세션 내부의 시간적 순서를 유지한 상태에서 분석하였다.

변수	의미	분석 활용
TimeStamp	센서 측정 시점	시간순 정렬, 측정 공백 및 연속 구간 판별
AI0_Vibration	진동 센서 신호	진동 크기 및 단기간 변화 분석
AI1_Vibration	진동 센서 신호	진동 크기 및 단기간 변화 분석
AI2_Current	모터 전류 신호	운전 상태 및 부하 변화 분석
Equipment_state	정상/이상 상태 정보	정답 확인 및 평가에만 사용

Equipment_state는 정상·이상 상태를 직접 나타내는 변수이므로 모델 입력에 포함할 경우 정답 정보가 그대로 전달되는 Target Leakage가 발생할 수 있다. 따라서 해당 변수는 학습 입력에서 완전히 제외하고 진동·전류 센서 정보만을 이용하였다.

○ 데이터 품질 및 측정주기 진단

전체 변수에 대해 결측치를 점검한 결과 정상 및 이상 데이터 모두에서 결측치는 확인되지 않았다. 중복 값 점검에서는 정상 데이터에서 동일 시점과 동일 센서값을 갖는 중복 측정 1건이 확인되어 시계열 특징 생성 이전에 제거하였다.

또한 TimeStamp를 분석한 결과 대부분의 데이터는 약 0.1초 간격으로 측정되었으나 일부 구간에서는 수 초의 측정 공백이 존재하였다. 이 상태에서 단순히 행 순서만을 이용하여 Rolling Feature를 계산하면 공백 이전의 센서 값과 공백 이후의 센서 값이 하나의 연속 신호처럼 결합될 수 있다.

이에 따라 기본 측정 간격 약 0.1초의 5배인 0.5초를 초과하는 시간 간격을 측정 공백으로 정의하고 해당 시점을 새로운 연속 측정구간(Segment)의 시작점으로 설정하였다. 측정되지 않은 진동 신호를 보간하여 인위적으로 생성하지 않고 각 Segment 내부에서 실제로 관측된 데이터만을 이용하였다.

센서의 큰 변화 값 역시 설비 이상징후 자체일 가능성이 있으므로 단순한 이상치로 판단하여 제거하지 않고 모델의 탐지대상으로 유지하였다.

○ 시계열 특징 생성

단일 시점의 센서 값만으로 이상을 판단할 경우 순간적인 정상 변동을 이상으로 오인할 가능성이 있으므로 최근 여러 관측 값의 변화 특성을 함께 반영하였다.

각 센서에 대해 원시 센서 값과 함께 다음 네 가지 시계열 특징을 생성하였다.

Rolling Mean: 최근 신호의 평균적인 수준

Rolling STD: 최근 신호의 변동 정도
RMS: 신호 크기를 종합적으로 나타내는 지표
PTP(Peak-to-Peak): 최근 구간의 최대 값과 최소 값의 차이
3개 센서에 대해 원시값 1개와 파생변수 4개씩을 구성하여 총 15개의 모델 입력변수를 생성하였다.
Rolling Feature는 공백을 넘어서 계산하지 않고 각 Segment 내부에서만 생성하였다. 또한 Window에 필요한 관측 값이 모두 확보된 이후부터 특징 값을 생성하도록 하여 서로 다른 개수의 관측 값으로 계산된 통계량이 혼재하지 않도록 하였다.

○ 검증전략 및 분석 목적 연결

시계열 데이터에서 미래의 관측 정보가 과거 학습구간으로 유입되는 것을 방지하기 위해 정상·이상 데이터 각각을 시간 순서대로 Train 60%, Validation 20%, Test 20%로 분할하였다. Random Split을 사용하지 않고 시간 순서를 보존하여 실제 현장에서 과거 데이터로 학습한 뒤 이후 데이터를 판단하는 상황과 유사한 검증환경을 구성하였다.

센서마다 값의 범위와 단위가 서로 다르므로 StandardScaler를 적용하였으며 스케일러는 정상 Train 데이터만을 이용하여 학습한 후 Validation 및 Test 데이터에 동일하게 적용하였다.

또한 데이터 불균형을 고려하여 Accuracy보다는 Precision, Recall, F1-score, ROC-AUC와 FP(False Positive), FN(False Negative)를 중심으로 성능을 평가하였다. 특히 정상 상태의 순간적인 진동·전류 변화를 이상으로 판단하는 오경보와 변화가 상대적으로 작은 이상 상태를 놓치는 미탐지를 구분하여 분석하는 것을 핵심 목표로 설정하였다.

□ 제2장. AI 예측모델 개발 및 성능평가 [40점]

○ 모델 구성 및 비교 전략

본 분석에서는 정상·이상 데이터의 불균형 구조와 실제 현장에서 이상 데이터가 충분히 확보되기 어렵다는 점을 고려하여 단일 모델에 의존하지 않고 Isolation Forest, Autoencoder, XGBoost 및 Hybrid Anomaly Score를 비교하였다.

Isolation Forest는 정상 데이터의 분포를 학습한 뒤 정상 패턴에서 벗어난 관측 값을 이상으로 판단하는 비지도 이상 탐지 모델로 구성하였으며 본 분석의 기준 모델이자 주 탐지 모델로 사용하였다. contamination=0.03으로 설정하고 정상 Train 데이터만을 이용하여 학습하였다.

Autoencoder는 정상 Train 데이터 15개 입력변수를 복원하도록 학습하였다. 구조는 15 → 16 → 4 → 16 → 15이며 정상 패턴과 입력 데이터 간 복원오차(MSE)를 이용하여 정상 패턴 이탈 정도를 산출하였다. 학습은 Adam optimizer와 MSE loss를 사용하여 25 epoch, batch size 64로 수행하였다.

XGBoost는 정상·이상 Train 데이터를 함께 이용하여 지도학습 기반의 보조 판별 모델로 구성하였다. n_estimators=100, max_depth=4, random_state=42를 적용하였으며 센서 및 시계열 파생변수의 비선형적 관계를 학습하도록 하였다.

마지막으로 XGBoost 이상 확률과 정규화된 Autoencoder 복원 오차를 각각 0.5의 가중치로 결합하여 Hybrid Anomaly Score를 구성하였다. 이 값은 통계적으로 보정된 확률이 아니라 여러 모델의 이상 신호를 종합한 위험도 점수로 정의하였다. Hybrid의 최종 판단 임계값은 Test 데이터를 사용하지 않고 Validation 데이터의 Precision-Recall 결과를 기준으로 F1-score가 최대가 되는 지점에서 결정하였으며 최종 임계 값은 0.3278로 산출되었

다.

○ Rolling Window 크기 선정

진동·전류 시계열의 최근 변화량을 어느 범위까지 반영할 것인지 결정하기 위해 3-Step, 5-Step, 10-Step을 후보로 설정하고 Validation 데이터에서 XGBoost와 Isolation Forest의 성능을 동시에 비교하였다.

Window	XGB Precision	XGB Recall	XGB F1	IF Precision	IF Recall	IF F1
3-Step	0.9538	0.5536	0.7006	0.2040	0.4554	0.2818
5-Step	**1.0000**	**0.6699**	**0.8023**	0.2177	0.5728	0.3155
10-Step	1.0000	0.6512	0.7887	**0.2833**	**0.7674**	**0.4138**

Isolation Forest 단독 성능은 10-Step에서 가장 높았으나 10-Step은 이상 판단에 더 많은 연속 관측 값이 필요하므로 현장 진단 시 초기 판단까지의 대기시간이 증가한다. 반면 5-Step은 XGBoost에서 가장 높은 Validation F1-score 0.8023을 기록하였고 Isolation Forest 역시 3-Step보다 Recall과 F1-score가 향상되었다.

따라서 단일 모델의 Validation 성능 최대화만을 기준으로 하지 않고 조기 판단을 위한 반응속도, 보조모델 성능 및 주 탐지 모델의 성능 향상을 종합적으로 고려하여 5-Step을 최종 Window로 선정하였다.

○ 동일 Test 조건에서의 모델 성능 비교

최종 5-Step 전처리를 적용한 후 동일한 Test 데이터에서 네 가지 모델을 평가하였다. 데이터의 클래스 불균형을 고려하여 Precision, Recall, F1-score, ROC-AUC뿐 아니라 실제 현장 활용에서 중요한 FP와 FN을 함께 비교하였다.

Model	Precision	Recall	F1-score	ROC-AUC	FP	FN
Isolation Forest	0.8228	**0.6250**	**0.7104**	0.9898	14	**39**
Autoencoder	0.9362	0.4231	0.5828	0.9942	3	60
XGBoost	**1.0000**	0.3654	0.5352	0.9524	**0**	66
Hybrid Anomaly Score	0.9348	0.4135	0.5733	**0.9943**	3	61

Isolation Forest는 Precision 0.8228, Recall 0.6250, F1-score 0.7104를 기록하여 네 모델 중 가장 높은 Recall과 F1-score를 나타냈다. 정상 데이터를 이상으로 잘못 판단한 FP는 14건이 발생하였으나 실제 이상 상태를 놓친 FN은 39건으로 다른 모델보다 가장 적었다.

Autoencoder는 Precision 0.9362와 ROC-AUC 0.9942로 정상과 이상을 구분할 수 있는 점수 분리능은 높았으나 Recall이 0.4231로 낮아 단독 탐지모델로 사용할 경우 상대적으로 많은 이상 상태를 놓치는 경향을 보였다.

XGBoost는 Precision 1.0000, FP 0건으로 탐지된 이상에 대한 신뢰도는 가장 높았으나 Recall이 0.3654로 낮고 FN이 66건 발생하였다. 따라서 이상 여부를 단독으로 탐지하는 모델보다는 명확한 이상 패턴을 보조적으로 확인하는 역할에 적합하다고 판단하였다.

Hybrid Anomaly Score 역시 Precision 0.9348, ROC-AUC 0.9943으로 높은 점수 분리능을 보였으나 Recall은 0.4135, F1-score는 0.5733으로 Isolation Forest보다 낮았다. 이에 따라 Hybrid Anomaly Score는 최종 분류 모델이 아니라 여러 모델의 이상 정도를 종합하여 현장 작업자에게 제공하는 위험도 지표로 활용하였다.

○ 최종 주 탐지 모델 선정

본 과제는 정상 운전 중 발생하는 오경보 감소뿐 아니라 실제 설비 이상을 놓치지 않는 것이 중요하다. 특히 제조설비의 이상 진단에서는 FP가 증가하면 불필요한 점검이 발생하지만 FN은 실제 이상 상태를 정상으로 판단하여 점검 시기를 놓칠 수 있다는 차이가 있다.

동일 Test 조건에서 Isolation Forest는 네 모델 중 가장 높은 Recall 0.6250과 F1-score 0.7104 그리고 가장 적은 FN 39건을 기록하였다. 또한 정상 데이터만으로 학습할 수 있어 이상 데이터 확보가 제한적인 실제 제조환경에서도 적용 가능하다는 장점을 가진다.

따라서 본 프로젝트에서는 Isolation Forest를 최종 주 탐지모델(Primary Anomaly Detector)로 선정하였다. Autoencoder는 정상 패턴 이탈 정도 산출, XGBoost는 지도학습 기반 보조 검증, Hybrid Score는 종합 위험도 표현에 활용하여 각 모델을 서로 다른 역할로 구성하였다.

최종 시스템은 다음과 같은 다층 구조로 설계하였다.

Isolation Forest 1차 이상 탐지

→ Autoencoder 정상 패턴 이탈도 산출

→ XGBoost 보조 판별

→ Hybrid Anomaly Score 위험도 제공

→ Persistence 기반 최종 경보 안정화

이를 통해 단순히 하나의 모델의 정확도를 높이는 것보다 탐지성능, 오경보 억제, 이상 위험도 해석 및 현장 경보 안정화를 동시에 고려하는 구조를 구축하였다.

제3장. 영향요인 및 오류분석 [15점]

○ 주요 영향변수 분석

이상 판단에 영향을 주는 주요 변수를 확인하기 위해 XGBoost의 Feature Importance를 분석하였다. 그 결과 상위 변수는 AI1_Vibration_roll_mean, AI0_Vibration_rms, AI2_Current_rms 순으로 나타났다.

순위	주요 변수	중요도
1	AI1_Vibration_roll_mean	0.5875
2	AI0_Vibration_rms	0.2998
3	AI2_Current_rms	0.0264
4	AI2_Current_ptp	0.0155
5	AI1_Vibration_roll_std	0.0154

특히 AI1_Vibration_roll_mean과 AI0_Vibration_rms가 전체 중요도의 대부분을 차지하여 이상 여부 판단 시 진동 신호의 평균 수준과 진동 크기 변화가 상대적으로 큰 영향을 미친 것으로 나타났다. 다만 Feature Importance는 모델의 판단 기여도를 나타내는 값이므로 특정 센서가 실제 고장의 물리적 원인이라고 직접 해석하지 않고 우선 점검이 필요한 신호로 활용하였다.

○ 주 탐지 모델의 오류 유형 분석

최종 주 탐지 모델인 Isolation Forest의 Test 결과를 TP(True Positive), TN(True Negative), FP(False Positive), FN(False Negative)으로 구분하였다.

구분	의미	건수
TP	실제 이상을 이상으로 탐지	65
TN	실제 정상을 정상으로 판정	3517
FP	실제 정상을 이상으로 오탐	14
FN	실제 이상을 정상으로 미탐	39

이 결과를 바탕으로 단순 F1-score뿐 아니라 탐지 성공 조건과 실패 조건의 센서 특징을 직접 비교하였다.

○ 미탐지(FN) 발생조건 분석

실제 이상 상태 중 탐지에 성공한 TP와 놓친 FN의 주요 파생변수 평균을 비교하였다.

주요 변수	TP 평균	FN 평균
AI0_Vibration_rms	0.3442	0.0527
AI0_Vibration_ptp	0.7247	0.1075
AI1_Vibration_rms	0.1947	0.0719
AI1_Vibration_ptp	0.3453	0.1180
AI2_Current_rms	275.0539	183.3187
AI2_Current_roll_std	58.4314	55.8285

TP에서는 AI0·AI1 진동의 RMS와 PTP가 FN보다 뚜렷하게 크게 나타났다. 반면 FN은 실제 이상 상태임에도 진동 크기와 변화폭이 상대적으로 작았다. 전류 RMS 역시 TP가 275.0539, FN이 183.3187로 차이가 나타났지만 전류 Rolling STD의 차이는 상대적으로 작았다.

따라서 본 데이터에서 Isolation Forest는 진동 크기나 변화폭이 명확한 이상상태는 비교적 잘 탐지하지만 센서 변화가 작게 나타나는 미세 이상 상태에서는 정상 패턴과의 구분이 어려워 미탐지가 발생하는 경향을 보였다.

즉 FN의 주요 발생조건은 다음과 같이 정리할 수 있다.

이상 상태이지만 AI0·AI1 진동의 RMS 및 PTP 변화가 크지 않고 전류 변화 역시 상대적으로 완만한 경우 미탐 가능성이 증가하였다.

○ 오경보(FP) 발생조건 분석

실제 정상상태 중 정상으로 판정한 TN과 이상으로 잘못 탐지한 FP의 주요 센서 특징을 비교하였다.

주요 변수	TN 평균	FP 평균
AI0_Vibration_rms	0.0479	0.1144
AI0_Vibration_ptp	0.1244	0.3041
AI1_Vibration_rms	0.0603	0.1902
AI1_Vibration_ptp	0.1587	0.5225
AI2_Current_rms	94.5812	182.9479
AI2_Current_roll_std	50.1587	82.9626

FP는 실제 정상 상태임에도 진동 RMS와 PTP가 TN보다 크게 나타났으며 특히 AI1_Vibration_ptp는 정상 판정 구간의 0.1587에서 오경보 구간의 0.5225로 크게 증가하였다. 전류 RMS와 변동성 역시 FP에서 더 높은 값을 보였다.

이는 정상 운전 중에도 순간적으로 진동이나 전류 변화가 크게 발생하는 구간이 존재하며 Isolation Forest가 이러한 정상 상태의 일시적인 센서 스파이크를 이상 패턴으로 판단하여 오경보가 발생했을 가능성을 보여준다.

따라서 FP의 주요 발생조건은 다음과 같이 정리할 수 있다.

정상 상태에서도 순간적인 진동 PTP·RMS 및 전류 변동성이 동시에 커지는 경우 이상 패턴과 유사하게 인식되어 오경보가 발생하였다.

○ Persistence 기반 오경보 억제 효과 및 한계

현장에서는 단일 시점의 이상 신호만으로 즉시 경보를 발생시키면 순간적인 센서 변동에 의해 불필요한 점검이 증가할 수 있다. 이를 보완하기 위해 Hybrid Anomaly Score에 최근 5개 판단 중 3개 이상이 이상일 때 최종 경보를 발생시키는 5-Step, 3-of-5 Persistence Rule을 적용하였다. 또한 측정 공백이 발생한 경우 이전 구간의 경보 상태가 이후 구간으로 이어지지 않도록 Segment별로 Persistence를 초기화하였다.

방식	Precision	Recall	F1-score	FP	FN
Hybrid 적용 전	0.9348	0.4135	0.5733	3	61
Hybrid + Persistence	**1.0000**	0.3558	0.5248	**0**	67

Persistence 적용 후 FP는 3건에서 0건으로 감소하여 정상 상태에서 발생하는 단발성 이상 신호를 효과적으로 억제하였다. 반면 FN은 61건에서 67건으로 증가하고 Recall과 F1-score는 다소 감소하였다.

따라서 Persistence는 탐지성능 자체를 높이는 기법이라기보다 **단발성 오경보를 억제하는 대신 일부 짧은 이상 신호에 대한 탐지 민감도를 희생하는 현장형 알람 안정화 장치**로 보았다.

○ 오류분석 종합

본 모델은 진동 RMS·PTP와 전류 RMS가 뚜렷하게 증가하는 이상 구간에서는 높은 탐지 가능성을 보였으나 신호 변화가 작은 이상 구간에서는 FN이 발생하였다. 반대로 정상 상태에서도 순간적으로 진동 및 전류 변동성이 크게 증가할 경우 FP가 발생하였다.

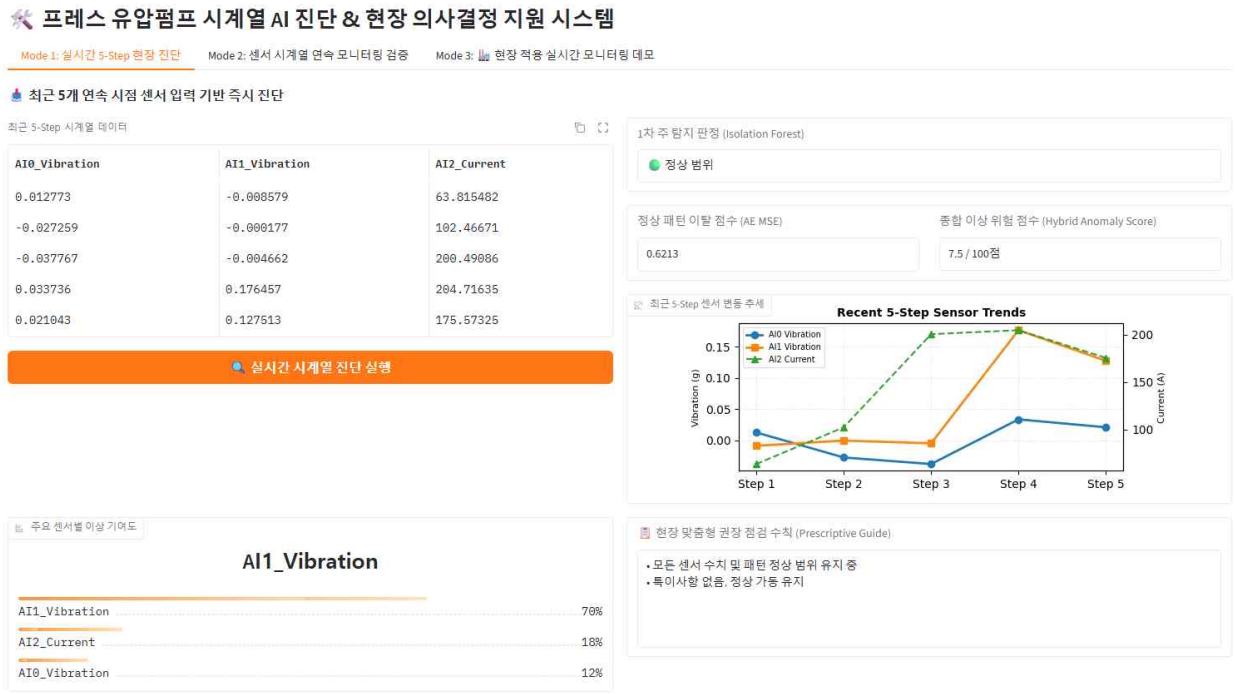
따라서 본 분석에서는 단일 모델의 평균 성능만으로 모델을 평가하지 않고 “변화가 작은 이상은 미탐될 수 있고 순간적인 정상 스파이크는 오경보를 유발할 수 있다”는 실패조건을 도출하였다. 이를 바탕으로 현장에서는 Isolation Forest의 1차 이상 탐지 결과와 Hybrid 위험도를 함께 확인하고 Persistence Rule을 선택적으로 적용하여 오경보와 미탐지 간의 균형을 조정할 수 있도록 구성하였다.

제4장. 현장 활용방안 [10점]

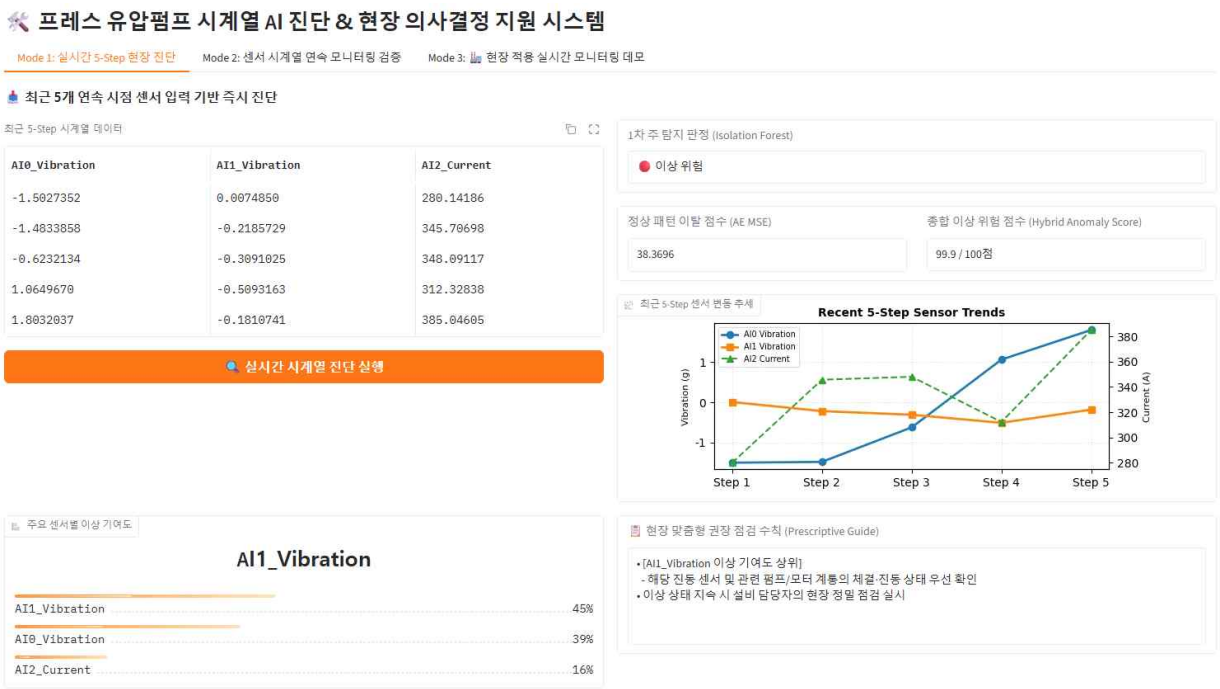
○ 실시간 설비상태 진단 및 의사결정 지원

본 프로젝트에서는 모델의 예측 결과가 단순한 정상·이상 분류에 그치지 않고 실제 작업자의 점검 판단으로 이어질 수 있도록 프레스 유압펌프 실시간 시계열 AI 진단 및 처방 시스템을 구현하였다. 시스템은 최근 연속 관측값을 이용한 Mode 1: 실시간 5-Step 현장 진단, 정상·이상 세션의 연속적인 탐지 특성을 확인하는 Mode 2: 센서 시계열 연속 모니터링 검증, 그리고 센서 스트림이 순차적으로 유입되는 상황을 가정한 Mode 3: 현장 모니터링 시뮬레이션으로 구성하였다.

Mode 1에서는 최근 5개의 AI0_Vibration, AI1_Vibration, AI2_Current 값을 입력하면 Isolation Forest의 1차 탐지 결과, Autoencoder 정상 패턴 이탈점수, Hybrid Anomaly Score, 최근 센서 변동 추세와 센서별 이상 기여도를 동시에 제공한다. 이를 통해 작업자는 단순히 “이상 발생” 여부만 확인하는 것이 아니라 어떤 센서의 변화가 상대적으로 크게 나타났는지와 이상 정도를 함께 확인할 수 있다.



[그림 4-1. 정상상태 연속 5개 관측값에 대한 실시간 진단 결과]



[그림 4-2. 이상상태 연속 5개 관측값에 대한 실시간 진단 결과]

○ 모델 출력에 따른 현장 판단 기준

현장에서는 하나의 출력 값만으로 설비를 즉시 정지시키기보다 여러 신호를 단계적으로 활용하도록 구성하였다.

진단 정보	현장 활용 방법
Isolation Forest	1차 정상/이상 상태 판단
AE MSE	정상 운전패턴에서 얼마나 벗어났는지 확인
Hybrid Anomaly Score	종합적인 이상 위험수준 확인
센서별 이상 기여도	우선 점검할 센서 및 관련 계통 선정
Persistence Alert	일시적 스파이크와 지속 이상을 구분하여 최종 경보 결정

Isolation Forest가 정상으로 판단하고 Hybrid 위험도가 낮은 경우에는 정상 운전을 유지한다. 반대로 Isolation Forest에서 이상이 탐지되거나 Hybrid 위험도가 상승하면 최근 센서 추세와 이상 기여도를 확인하여 변화가 크게 나타난 센서와 관련된 펌프·모터 계통을 우선 점검하도록 하였다.

예를 들어 진동 센서의 이상 기여도가 상대적으로 높게 나타나는 경우에는 해당 진동 센서 및 펌프·모터 계통의 체결 및 진동 상태를 우선 확인하고 전류 센서의 기여도가 높게 나타날 경우에는 모터 전류와 구동상태를 우선 확인하는 방식이다. 다만 센서 기여도는 모델 판단에 대한 상대적 기여를 의미하므로 특정 고장 원인을 자동 확정하는 용도로 사용하지 않고 점검 우선순위를 제공하는 보조 정보로 활용한다.

○ 오경보 억제를 위한 최종 경보 판단

제3장의 오류분석 결과 정상 상태에서도 순간적인 진동 및 전류 변동 증가에 의해 FP가 발생할 수 있음을 확인하였다. 이에 따라 단일 시점의 이상 판정을 즉시 현장 경보로 변환하지 않고 최근 판단의 지속성을 확인하는 Temporal Persistence Rule을 추가하였다.

Hybrid Anomaly Score가 일시적으로 임계 값을 초과하더라도 즉시 최종 경보를 발생시키지 않고 최근 5개의 판단 중 3회 이상 이상 상태가 확인될 때 최종 경보를 발생시키도록 하였다. 이를 통해 순간적인 센서 스파이크에 의한 불필요한 경보를 줄이고 반복적으로 나타나는 이상 신호를 우선적으로 작업자에게 전달할 수 있도록 하였다.

다만 Persistence 적용 시 일부 짧은 이상 신호가 제거되면서 미탐지가 증가할 수 있으므로 이를 설비의 이상 여부를 결정하는 단독 모델로 사용하지 않고 현장 알람 안정화를 위한 후처리 단계로 활용하였다.

○ 측정 공백 발생 시 안전한 진단 재개

실제 데이터에서는 대부분 약 0.1초 간격으로 센서값이 수집되지만 일부 구간에서 수 초의 측정 공백이 확인되었다. 이러한 공백 전후의 데이터를 연속신호로 처리하면 실제 시간적으로 떨어진 데이터가 동일한 Rolling Window나 Persistence 판단에 포함될 수 있다.

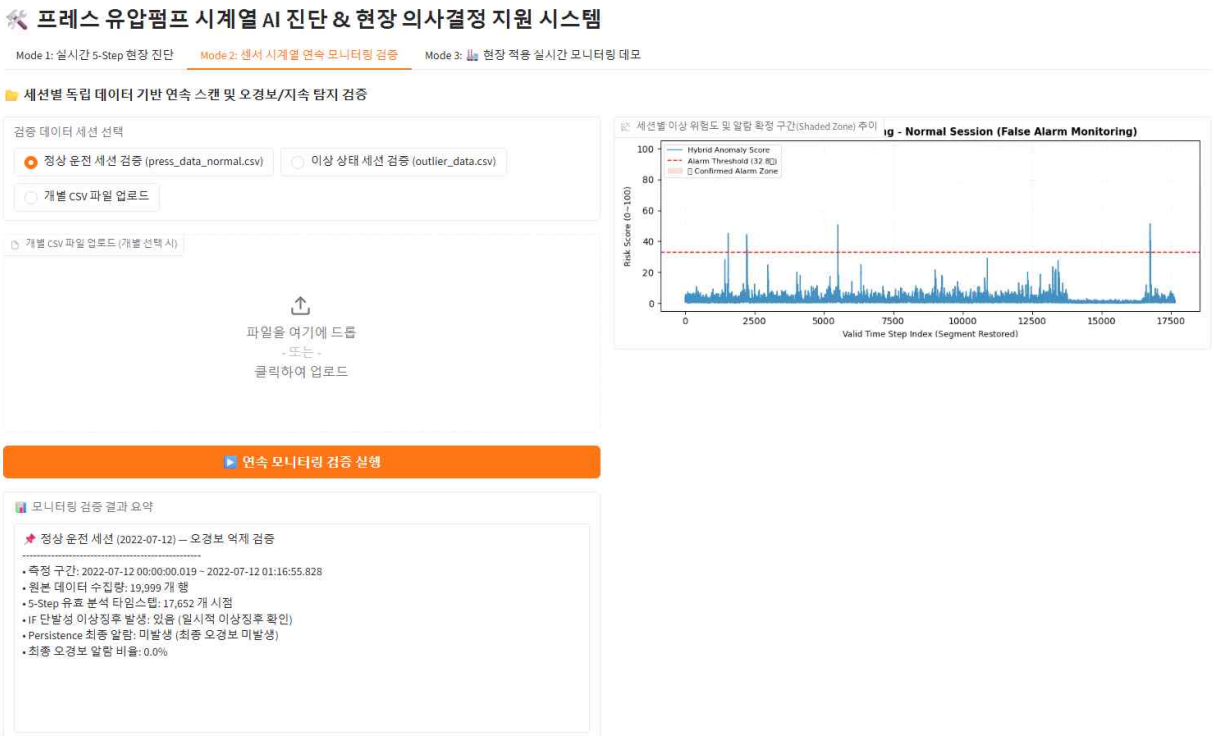
따라서 0.5초를 초과하는 측정 공백이 발생하면 기존 시계열 상태를 초기화하고 새로운 연속 측정구간으로 처리하였다. 이후 연속 관측값 5개가 다시 확보된 뒤 AI 진단을 재개하도록 구성하였다.

현장 적용 시에도 동일한 원칙을 적용하여

센서 데이터 정상 수집 → 5개 관측값 확보 → AI 진단 → 측정 공백 발생 시 진단상태 초기화 → 데이터 재수집 → 5개 확보 후 진단 재개

의 흐름으로 운용할 수 있다. 이는 측정되지 않은 신호를 임의 보간하여 판단하기보다 실제 확보된 센서 정보만으로 보수적으로 판단하기 위한 것이다.

○ 정상·이상 세션 기반 연속 모니터링 검증



[그림 4-3. 정상 운전 세션의 연속 모니터링 검증 결과]



[그림 4-4. 이상 상태 세션의 연속 모니터링 검증 결과]

Mode 2에서는 제공된 정상 및 이상 세션을 각각 시간순으로 입력하여 모델이 장시간 연속 데이터에서 어떤 경보 특성을 보이는지 확인하도록 하였다. 정상 세션에서는 순간적인 이상징후가 발생하더라도 Persistence 적용 후

최종 경보가 지속되는지를 확인하여 오경보 억제 성능을 검증한다.

이상 세션에서는 이상상태 데이터가 연속 입력될 때 1차 이상 탐지와 최종 Persistence 경보가 지속적으로 유지되는지를 확인하여 이상 상태에 대한 연속 감시 가능성을 검증한다.

두 파일은 서로 다른 날짜에 수집된 독립 세션이므로 이를 연결하여 "고장 발생 몇 초 전 탐지"라고 해석하지 않았다. 대신 정상 세션에서는 오경보 억제, 이상 세션에서는 이상상태 탐지 및 지속 감시라는 서로 다른 현장 활용 목적을 검증하였다.

○ 최종 현장 운영 시나리오

최종적으로 본 시스템은 다음과 같은 현장 의사결정 흐름을 목표로 한다.

센서 데이터 수집

→ 연속 5개 관측값 기반 특징 생성

→ Isolation Forest 1차 이상탐지

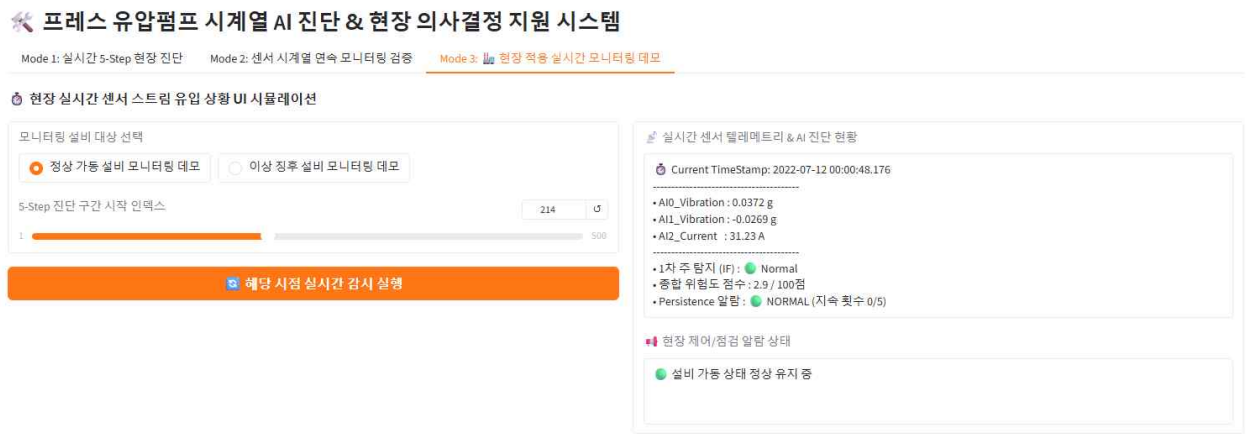
→ AE 및 Hybrid Score로 위험도 보조 확인

→ 센서별 기여도로 점검 우선순위 선정

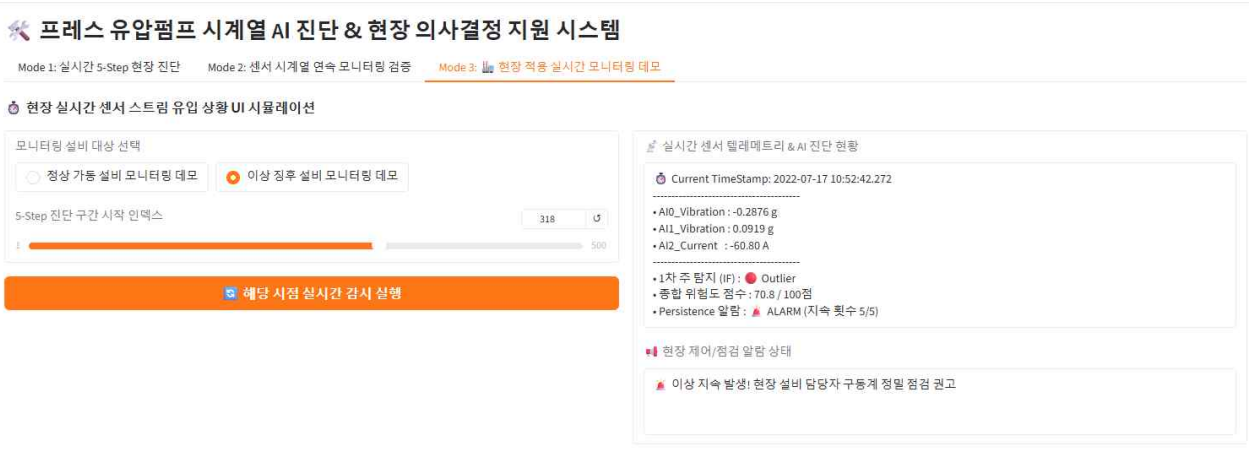
→ Persistence로 단발성 오경보 억제

→ 지속 이상 시 작업자 점검 실시

이를 통해 오프라인 모델 평가에서 나아가 실제 센서 데이터가 순차적으로 유입되는 상황을 가정한 현장 의사결정 지원 시뮬레이션 형태로 확장하였다.



[그림 4-5. 정상 가동상태의 실시간 센서 스트림 모니터링 시뮬레이션]



[그림 4-6. 이상 지속상태의 실시간 센서 스트림 경보 시뮬레이션]

실제 현장 적용 상황을 가정하여 센서 데이터가 순차적으로 유입되는 실시간 모니터링 UI를 구현하였다. 정상 가동 시에는 Isolation Forest, Hybrid Anomaly Score 및 Persistence 결과를 종합하여 정상 운전 상태를 표시하고 지속적인 이상 신호가 확인되는 경우에는 최종 ALARM을 발생시켜 현장 설비 담당자의 규정에 따른 정밀 점검을 유도하도록 구성하였다. 이를 통해 본 시스템은 오프라인 모델 평가를 넘어 실제 작업자가 사용할 수 있는 실시간 의사결정 지원 형태로 확장하였다.

□ 제5장. 창의성 및 차별성 [10점]

○ 단일 정확도 중심이 아닌 다층 이상진단 구조

본 프로젝트의 차별점은 하나의 알고리즘으로 정상·이상을 단순 분류하는 방식에서 벗어나 각 모델의 장점을 서로 다른 역할에 활용한 다층 이상진단 구조를 구성한 점이다.

Isolation Forest는 정상 데이터의 분포를 기반으로 이상상태를 탐지하는 1차 주 탐지모델로 사용하였고 Autoencoder는 정상 패턴으로부터의 이탈 정도를 복원오차로 정량화하였다. XGBoost는 정상·이상 라벨을 활용한 보조 판별모델로 사용하였으며 XGBoost 이상확률과 Autoencoder 점수를 결합한 Hybrid Anomaly Score를 통해 단순 이진판정 외에 종합적인 이상 위험수준을 제시하였다.

제2장의 동일 Test 비교에서 Isolation Forest가 Recall 0.6250, F1-score 0.7104로 가장 높은 이상 탐지성능을 보여주 탐지모델로 선정하였으며 Precision이 높은 XGBoost와 분리능이 높은 Autoencoder·Hybrid Score는 단독 최종판정이 아닌 보조 진단정보로 활용하였다. 즉 모든 모델을 동일 목적으로 사용하는 것이 아니라 각 모델의 성능 특성에 따라 역할을 분담하였다.

○ 실제 수집구조를 반영한 Segment 기반 시계열 특징 생성

초기 데이터 진단 과정에서 대부분 약 0.1초 간격으로 측정되지만 일부 구간에서는 수 초의 Timestamp 공백이 존재함을 확인하였다. 단순 행 순서 기반 Rolling Window를 사용할 경우 공백 이전과 이후의 센서값이 하나의 연속적인 신호처럼 결합되는 문제가 발생할 수 있다.

이를 해결하기 위해 0.5초 초과 공백을 새로운 연속 측정구간(Segment)의 시작점으로 정의하고 Segment 내부에서만 Rolling Mean, STD, RMS, PTP를 생성하였다. 또한 새로운 Segment에서는 연속된 관측값이 충분히 확보된 이후에만 진단을 수행하도록 구성하였다.

측정되지 않은 구간을 보간하여 인위적인 진동 데이터를 생성하지 않고 실제 측정값만을 사용하는 방식을 선택함으로써 모델 성능뿐 아니라 현장 센서 데이터의 물리적인 시간구조를 고려하였다.

○ 탐지성능과 현장 반응성을 동시에 고려한 5-Step 선정

Rolling Window 역시 임의로 고정하지 않고 3, 5, 10-Step을 비교하였다. Isolation Forest는 10-Step에서 가장 높은 Validation F1-score를 보였으나 10개의 연속 관측값이 확보되어야 판단할 수 있어 초기 경보 지연이 증가한다.

반면 5-Step은 3-Step보다 Isolation Forest 성능이 개선되었고 XGBoost에서는 가장 높은 Validation F1-score를 기록하였다. 이에 따라 단순히 한 모델의 최고 성능만을 선택하는 대신 탐지성능과 현장 반응속도의 균형을 고려하여 5-Step을 최종 적용하였다.

이는 모델의 정량 성능뿐 아니라 실제 설비 이상을 얼마나 신속하게 확인할 수 있는지를 함께 고려한 설계이다.

○ 오류분석 결과를 반영한 Persistence 경보 안정화

제3장의 오류분석 결과, 정상상태에서도 순간적인 진동 RMS·PTP 및 전류 변동성이 증가하면 FP가 발생하는 반면 실제 이상임에도 신호 변화폭이 작을 경우 FN이 발생하는 특성을 확인하였다.

이에 따라 순간적인 모델 출력 하나를 그대로 현장 경보로 전달하지 않고 최근 5개 판단 중 3회 이상 이상 신호가 확인될 때 최종 경보를 발생시키는 Temporal Persistence Rule을 적용하였다.

그 결과 Hybrid Score 기준 FP가 3건에서 0건으로 감소하여 일시적인 정상 스파이크에 의한 최종 오경보를 제거할 수 있었다. 반면 FN은 61건에서 67건으로 증가하여 일부 짧은 이상에 대한 민감도가 낮아지는 한계도 확인하였다.

따라서 Persistence를 성능을 무조건 향상시키는 기법으로 제시하지 않고 오경보 감소와 미탐 증가 사이의 Trade-off를 조절하는 현장 경보 안정화 계층으로 사용하였다. 이는 제3장의 오류분석 결과를 실제 시스템 설계에 직접 반영한 것이다.

○ 분석모델에서 현장 의사결정 시스템으로의 확장

본 프로젝트에서는 모델 성능평가에서 종료하지 않고 Gradio 기반의 현장 진단 인터페이스까지 구현하였다.

Mode 1에서는 최근 5개 연속 센서값을 입력하여 Isolation Forest 판정, Autoencoder MSE, Hybrid Anomaly Score, 센서 변화 추세, 센서별 이상 기여도 및 점검 가이드를 함께 제공한다. Mode 2에서는 정상·이상 세션 전체를 시간순으로 재생하여 오경보 억제와 지속 이상 감시 특성을 검증한다. 또한 Mode 3에서는 실시간 센서 스트림이 순차 유입되는 상황을 가정한 UI를 통해 Persistence 경보와 작업자 점검상태까지 연결하였다.

이를 통해 본 시스템은

센서 수집 → 시계열 특징 생성 → 이상 탐지 → 위험도 산출 → 센서별 점검 우선순위 제시 → 지속성 검증 → 작업자 점검

으로 이어지는 전체 의사결정 흐름을 구현하였다.

○ 차별성 종합

본 프로젝트의 차별성은 새로운 알고리즘 하나를 제안한 데 있지 않고 실제 데이터 수집 구조와 오류 특성을 분석한 후 그 결과를 다시 전처리·모델·경보·현장 UI 설계에 반영했다는 점에 있다.

특히 ① Target Leakage가 발생할 수 있는 Equipment_state 제거, ② 측정 공백을 고려한 Segment 기반 Rolling, ③ 다중 모델의 역할 분담, ④ FP/FN 분석을 반영한 Persistence 경보, ⑤ 센서별 기여도와 점검 가이드 제공, ⑥ 실시간·세션 단위 현장 모니터링 UI 구현을 하나의 파이프라인으로 연결하였다.

이를 통해 단순 분류 정확도 중심의 분석보다 이상 탐지 성능, 오경보 억제, 오류 해석 및 현장 활용성을 함께 고려한 제조설비 진단체계를 제안하였다.

□ 제6장. 코드 구성 및 재현성 [10점]

○ 전체 코드 구성

본 분석 코드는 Google Colab(Python 3.13.15) Notebook 기반으로 구성하였으며, 데이터 로드 및 정제부터 시계열 전처리, 모델 학습, 성능평가, 오류분석, Persistence 후처리 및 Gradio 기반 현장 모니터링 화면까지 순차적으로 실행할 수 있도록 하나의 파이프라인으로 구성하였다.

전체 실행 순서는 다음과 같다.

실행 단계 주요 내용

실행 단계	주요 내용
Cell 0	데이터 로드, 불필요 인덱스 제거, 중복 측정 1건 제거, Global Seed 고정
Cell 1	TimeStamp 정렬, 0.5초 초과 공백 Segment 분리, Rolling Feature 생성, 시간순 Train/Validation/Test 분할 및 표준화
Cell 1.5	3・5・10-Step Window Size Validation 비교
Cell 2	Isolation Forest, Autoencoder, XGBoost 학습 및 Hybrid Score 산출, Validation 기반 임계값 최적화, Test 성능평가
Cell 3	Segment 기반 Temporal Persistence 적용 및 전후 성능 비교
Cell 3.5	Test 데이터의 모델별 예측 값 및 최종 Persistence 결과를 prediction_result.csv로 자동 저장
Cell 4	Isolation Forest 기준 FP/FN 특징량 분석
Cell 5	Gradio 기반 Mode 1・2・3 현장 진단 및 모니터링 UI 실행

따라서 Notebook을 위에서부터 순차 실행하는 것만으로 동일한 전처리 과정과 모델 학습, 성능지표 산출 및 현장 모니터링 결과를 확인할 수 있도록 구성하였다.

○ 입력 데이터 및 자동 전처리

입력 데이터는 press_data_normal.csv와 outlier_data.csv 두 파일이며 Notebook 실행 시 pandas를 이용해 자동으로 로드한다. 이후 저장 과정에서 생성된 불필요한 인덱스 컬럼을 제거하고 실제 센서 측정정보를 기준으로 정상 데이터의 중복 측정 1건을 제거한다.

TimeStamp는 datetime 형식으로 변환한 후 시간순으로 정렬하며 인접 관측 간 시간 차가 0.5초를 초과할 경우 새로운 Segment로 구분한다. 각 Segment 내부에서만 Raw, Rolling Mean, Rolling STD, RMS, PTP를 계산하고 Window Size가 충족되지 않은 행은 모델 입력에서 제외한다.

데이터는 정상·이상 세션별 시간순으로 Train 60%, Validation 20%, Test 20%로 분할하며 StandardScaler는 정상 Train 데이터에만 적합한 뒤 나머지 데이터에 동일하게 적용하여 정보누설을 방지하였다.

○ 모델 학습 및 결과 자동 생성

Isolation Forest는 정상 Train 데이터만을 이용하여 정상 패턴과의 이탈 정도를 학습하고, Autoencoder 역시 정상 Train 데이터의 정상 패턴을 복원하도록 학습하였다. XGBoost는 정상·이상 Train 데이터를 함께 사용하여 지도학습 기반의 보조 판별모델로 구성하였다.

모델 실행 시 무작위성에 따른 결과 변동을 최소화하기 위해 Python, NumPy, TensorFlow의 Random Seed를 42

로 통일하였으며, Isolation Forest와 XGBoost에도 random_state=42를 적용하였다. 이를 통해 동일한 데이터와 실행환경에서 반복 실행할 경우 가능한 한 일관된 분석결과가 생성되도록 구성하였다.

Validation 데이터는 모델 선택 및 Hybrid Anomaly Score의 판단 임계값 결정에 사용하고 Test 데이터는 최종 성능평가에만 사용하도록 분리하였다. 모델 학습 완료 후에는 Precision, Recall, F1-score, ROC-AUC, FP, FN을 자동 산출하며 XGBoost Feature Importance와 Isolation Forest의 TP/FN 및 TN/FP 특징량 비교 결과도 자동으로 생성되도록 구현하였다.

또한 Temporal Persistence 적용 전후의 Precision, Recall, F1-score, FP, FN을 자동 비교하여 오경보 감소와 미탐 증가 사이의 Trade-off를 동일한 실행환경에서 확인할 수 있도록 하였다.

○ 추론 및 현장 UI 재현

최종 Cell에서는 Gradio 기반의 현장 진단 시스템을 실행하도록 구성하였다.

Mode 1은 최근 5개 연속 센서값을 입력받아 Isolation Forest 판정, Autoencoder MSE, Hybrid Anomaly Score, 센서 추세, 센서별 기여도 및 점검 가이드를 출력한다.

Mode 2는 정상 또는 이상 CSV 전체를 시간순으로 입력하여 시계열 위험도, Persistence 최종 알람, 세션 내 알람 유지 비율 및 최근 진단 로그를 자동 생성한다.

Mode 3은 실제 센서 스트림이 순차 유입되는 상황을 가정하여 특정 Time Index에서의 센서값, AI 진단결과, Persistence 상태 및 현장 점검 알람을 실시간 형태로 확인할 수 있도록 구성하였다.

이를 통해 학습용 코드와 별개의 수작업 계산 없이 동일 Notebook 안에서 학습 → 평가 → 추론 → 현장 UI 결과생성까지 재현할 수 있도록 하였다.

○ 실행환경 및 제출 파일 구성

본 프로젝트는 Python 기반으로 작성되었으며 주요 라이브러리는 pandas, numpy, scikit-learn, xgboost, tensorflow, matplotlib, gradio이다.

최종 제출 시에는 평가자가 동일 환경을 쉽게 구성할 수 있도록 다음 파일을 함께 제공한다.

- 소스코드 (.ipynb)
- press_data_normal.csv
- outlier_data.csv
- requirements.txt
- 실행순서 및 파일구조를 설명한 README
- 테스트 데이터 예측결과 파일

○ 재현성 확보를 위한 설계

본 코드에서는 데이터 파일명, 전처리 기준, Window Size, Segment 기준, 모델 파라미터 및 Validation/Test 분리 규칙을 코드 내부에 명시하여 실행자에 따른 임의적 판단을 최소화하였다. 또한 주요 모델 성능지표와 대시보드의 핵심 진단 수치는 실제 데이터와 모델 출력으로부터 자동 계산되도록 구성하여 코드와 보고서 결과의 정합성을 확보하였다.

이러한 구조를 통해 평가자가 동일한 데이터와 실행환경에서 Notebook을 위에서부터 순차적으로 실행하면 데이터 정제 → 시계열 특징 생성 → 모델 학습 → 성능평가 → 오류분석 → Persistence 적용 → 현장 모니터링 결과까지 동일한 분석 흐름을 재현할 수 있도록 하였다.

□ 경진대회 만족도 조사 완료 페이지 캡쳐 화면(필수)

- 만족도 조사 url : https://naver.me/FetWt7SN

